LAPORAN EVALUASI SISTEM

RAG SYSTEM

Adam Noverian	**2443110**
Alfiansyah Wahyu P	**2443110**
Ghofur Akbar M.	**244311042**

PROGRAM STUDI TRPL
JURUSAN TEKNIK
POLITEKNIK NEGERI MADIUN

2026

1. Deskripsi Sistem & Tech Stack

1.1 Deskripsi Sistem

Tujuan sistem

- Untuk membangun sistem yang mampu memberikan jawaban dalam Bahasa Indonesia atas pertanyaan pengguna berdasarkan dokumen yang tersedia di folder `data/`.

Alur kerja utama (end-to-end)

1. Document loading (`src/indexing.py`)

   - Membaca dokumen dari `data/`:

     - PDF via `pypdf`

     - TXT via file read

     - CSV via `pandas`, lalu digabung (*merge*) berdasarkan kolom `name` dan diubah menjadi baris-baris teks `nama | harga | deskripsi`.

2. Chunking (`src/indexing.py`)

   - Dokumen dipecah menjadi *chunks* berbasis karakter dengan `chunk_size` dan `chunk_overlap`.

3. Embedding (`src/embeddings.py`, dipakai oleh `src/indexing.py` dan `src/query.py`)

   - Menggunakan `sentence-transformers` dan model lokal `models/paraphrase-multilingual-mpnet-base-v2`.

   - *Embedding* dinormalisasi (`normalize_embeddings=True`) agar cocok dengan pencarian *Inner Product*

4. Vector indexing (`src/indexing.py`)

   - Membuat index FAISS `IndexFlatIP` dan menyimpan ke `faiss_index.index`.

   - Menyimpan `chunks` + `metadata` (minimal: `source`) ke `chunks.pkl`.

5. Query + Hybrid retrieval (`src/query.py`)

   - Semantic search: FAISS (inner product pada embedding ter-normalisasi).

   - Keyword search: BM25 (`rank-bm25`) dengan tokenisasi sederhana (`lower().split()`).

- Skor digabung (default) `alpha=0.65` semantic + `0.35` BM25 untuk memilih Top-K chunk.

6. Jawaban LLM (`src/query.py`)

- Mengirim konteks Top-K chunk ke `ollama.chat()` (model dipilih di UI).

- Sistem prompt memaksa jawaban berbasis konteks dan melarang mengarang.

7. UI & kontrol parameter (`ui/app.py`)

- Streamlit menyediakan:

  - pemilihan model Ollama (`llama3.1:8b`, `qwen2.5:3b`, `mistral:7b`)

  - pengaturan `Top-K`, `chunk_size`, `chunk_overlap`

  - tombol untuk menjalankan indexing dan chat interface multi-turn.

Artefak penting yang dihasilka

- `faiss_index.index`: index vektor (FAISS)

- `chunks.pkl`: daftar chunk + metadata sumber

- `models/paraphrase-multilingual-mpnet-base-v2/`: model embedding lokal (untuk mode offline)

1.2 Tech Stack & Justifikasi

Komponen	Teknologi	Alasan Pemilihan
Orchestration	Full From Scratch	(Python modular: `src/indexing.py`, `src/query.py`, `src/embeddings.py`) | Mudah dipahami untuk UTS, Dan sesuai dengan struktur dari starter pack yang diberikan
Large Language Model	Ollama "paraphrase-	Mendukung Bahasa Indonesia dengan baik, Gratis dan bisa dijalankan secara lokal

	multilingual-mpnet-base-v2"	
Vector Database	FAISS (CPU) + penyimpanan metadata via `pickle` (`chunks.pkl`)	FAISS cepat dan ringan untuk *vector similarity search* lokal; cocok untuk skala kecil–menengah. Metadata disimpan sederhana tanpa dependensi DB tambahan.
Frontend UI	Streamlit	Cepat untuk prototyping UI chat, mudah menambahkan kontrol parameter (Top-K, chunk size/overlap), dan cocok untuk demo UTS.
Document Loader	pypdf, pandas	`pypdf` sederhana untuk ekstraksi teks PDF; `pandas` memudahkan baca/merge CSV; implementasi loader ringan untuk data lokal

Teknologi pendukung (yang dipakai langsung di pipeline):
- Embeddings: `sentence-transformers` (model lokal `paraphrase-multilingual-mpnet-base-v2`) + `torch` untuk device CPU/GPU.
- LLM runtime: `ollama` untuk inference model lokal dengan API chat.
- Hybrid retrieval: `rank-bm25` untuk keyword scoring, `numpy` untuk vektor.

2. Evaluasi Sistem

Evaluasi berikut disusun sebagai *test set* sebanyak 10 pertanyaan yang relevan dengan data pada folder `data/` (CSV harga & deskripsi laptop, serta PDF spesifikasi).

Tabel Evaluasi

No	Pertanyaan	Jawaban Sistem (Ringkasan)	Jawaban Ideal	Skor (1–5)
1	Berapa harga Lenovo ThinkPad T14 Gen 1 Core i7 Touchscreen?	Harga Lenovo ThinkPad T14 Gen 1 Core i7 Touchscreen adalah Rp	Harga: 3.850.000	5

		3.850.000,0.		
2	Jelaskan singkat deskripsi Lenovo ThinkPad T14 Gen 1 Core i7 Touchscreen	Lenovo ThinkPad T14 Gen 1 Core i7 Touchscreen adalah laptop modern dengan performa tinggi dan layar touchscreen. Cocok untuk kerja berat. Harganya Rp 3.850.000,0.	Laptop modern dengan performa tinggi dan layar touchscreen. Cocok untuk kerja berat.	5
3	Apa laptop termurah di dataset, dan berapa harganya?	Laptop termurah di dataset adalah Lenovo G40-30 Celeron N2840 dengan harga Rp 1.190.000,0.	Acer Aspire One D270: 400.000	1
4	Apa laptop termahal di dataset, dan berapa harganya?	Laptop termahal di dataset adalah HP EliteBook 845 G8 Ryzen 5 Pro 5650U dengan harga Rp 3.900.000.000	Advan Gaming Pixwar Ryzen 7 6800H Touchscreen: 9.199.000	1
5	Sebutkan jumlah laptop dengan harga > 3.000.000	Jumlah laptop dengan harga > 3.000.000 adalah 14 unit.	43 item	1
6	Sebutkan jumlah laptop dengan harga ≤ 1.000.000	Jumlah laptop dengan harga ≤ 1.000.000 adalah 9 unit.	19 item.	1
7	Jika saya tanya “Apakah ada laptop dengan harga 50 juta?”, apa seharusnya responnya?	Informasi tidak tersedia dalam dokumen tentang laptop dengan harga 50 juta.	Informasi tidak tersedia dalam dokumen	5
8	sumber dokumen apa saja yang kamu miliki untuk dipakai	Saya memiliki beberapa dokumen sebagai referensi: ...	sumber dari metadata `source` (contoh: `harga_laptop.csv`,	5

	menjawab pertanyaan.		`deskripsi_laptop.csv`, atau PDF terkait)	
9	laptop yang tadi itu cocok untuk apa?	Dari dokumen yang disediakan, saya tidak menemukan informasi tentang "laptop yang tadi itu". Mohon klarifikasi atau pertanyaan lainnya.	Jawaban konsisten mengacu konteks sebelumnya (chat_history) tanpa mengarang di luar dokumen.	1
10	Tampilkan 3 laptop harga di atas 3 juta beserta harganya	Dari dokumen yang disediakan, saya menemukan tiga laptop dengan harga di atas Rp 3.000.000 sebagai berikut:	Menampilkan 3 item valid + harga sesuai dokumen, tanpa memasukkan yang < 3 juta.	5
Rata-rata Skor:				**3.3/5.0**

3. Analisis Kelemahan & Saran Perbaikan

3.1 Analisis Kelemahan

1. BM25 dihitung ulang setiap query

- Di `src/query.py`, BM25 dibuat dari seluruh `chunks` setiap kali query dipanggil, sehingga makin lambat saat jumlah chunk besar.

2. Tokenisasi BM25 sangat sederhana

- Menggunakan `lower().split()`; tidak ada normalisasi, stopword removal, stemming, atau penanganan tanda baca → kualitas keyword retrieval bisa turun.

3. Model embedding & index tidak di-cache

- `get_embedding_model()` dipanggil saat query sehingga bisa berulang memuat model (mahal) jika tidak ada caching di level aplikasi.

4. Metadata minim

- Saat indexing, metadata hanya menyimpan `source` tanpa info halaman PDF, posisi chunk, atau atribut CSV → sulit membuat sitasi yang presisi.

5. Chunking berbasis karakter

- Risiko memotong kalimat/tabel di tengah, terutama dari PDF → konteks kurang rapi dan bisa menurunkan kualitas jawaban.

6. Penggabungan CSV berpotensi duplikasi

- Merge berdasarkan `name` dapat menghasilkan duplikasi baris jika ada `name` yang muncul lebih dari sekali pada salah satu file CSV.

7. Kontrol konteks chat belum adaptif

- Chat history ditambahkan terus ke prompt; tanpa truncation/summarization berisiko melebihi `num_ctx`.

3.2 Saran Perbaikan

- Cache resource di Streamlit (mis. model embedding dan hasil `load_index()`) agar query lebih cepat.
- Bangun BM25 sekali saat load index, simpan tokenisasi/chunks, lalu reuse untuk query berikutnya.
- Perkaya metadata: `source`, `page`, `chunk_id`, dan (untuk CSV) `name/price` sebagai field terstruktur.
- Upgrade chunking: berbasis paragraf/sentence (atau aturan khusus untuk tabel/CSV) dan simpan mapping chunk ↔ dokumen.
- Tambahkan *post-retrieval reranking* (mis. cross-encoder ringan) untuk meningkatkan relevansi Top-K.
- Validasi & deduplikasi data CSV sebelum merge (handle duplikat `name` secara eksplisit).
- Tambahkan mekanisme ringkas riwayat chat (*conversation summarization*) atau batasi jumlah turn yang dikirim ke LLM.
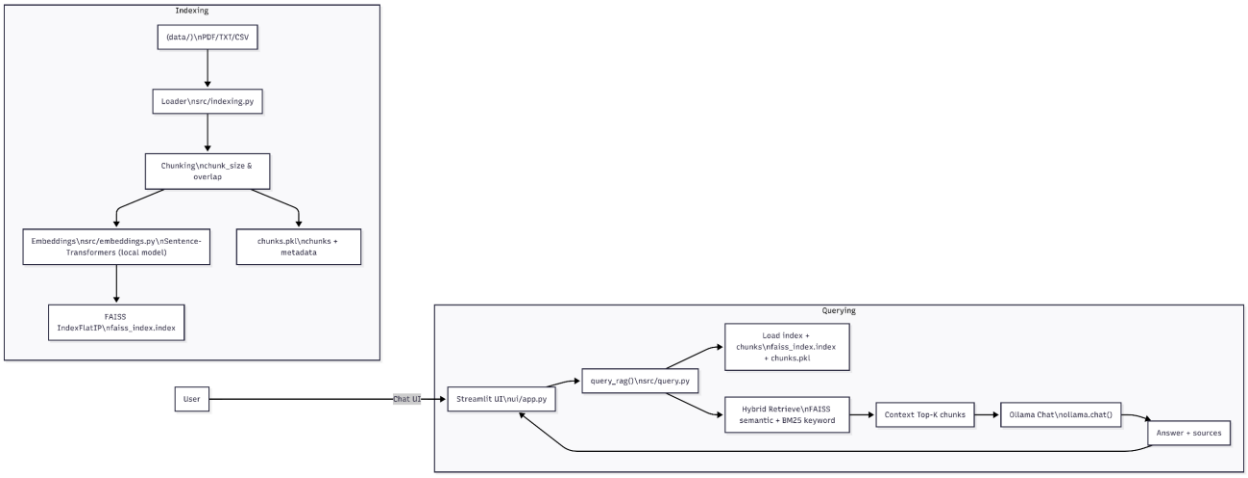
4. Diagram Arsitektur Sistem